Laboratório 2 - Ciclo de treino, vazamento e métricas

Deep Learning · CESAR School · Entrega individual · Valor: 1,0 ponto na AV1

Prazo: 08/10/2026. O horário limite é o cadastrado na atividade do Classroom.

Neste laboratório, a pergunta é: que evidências permitem confiar no resultado de um classificador? Você construirá uma forma de carregar dados, justificará sua separação, reproduzirá dois vazamentos e produzirá um relatório de métricas com uma decisão de limiar. A avaliação considera a execução e a explicação do processo; não exige atingir uma acurácia mínima.

Esta versão usa uma base pública comum à turma. Você não precisa ter um banco do projeto pronto. As Partes A, B2 e D usam Red Wine Quality; a Parte C usa uma cópia de desenvolvimento dessa base ou outro conjunto claramente identificado. Os cinco cenários da B1 são exercícios de raciocínio e não exigem baixar outras bases.

1. Comece por aqui

1. Extraia o ZIP inteiro. Não abra o notebook dentro do arquivo compactado.
2. Leia o problema e o dicionário em dados/DICIONARIO.md.
3. Abra lab02.ipynb. Execute a preparação e confira a leitura do CSV.
4. Faça B2 antes de A: os conjuntos precisam estar separados antes de calcular média e desvio.
5. Complete A, C e D. A ordem de programação da D começa pela parada antecipada (D7), depois pela escolha de custos e limiar, e termina na avaliação final.
6. Preencha README.md e USO-DE-IA.md. Reinicie o ambiente e execute tudo antes de enviar.

O notebook é um ponto de partida: contém explicações, funções de apoio e lugares marcados TODO para as implementações avaliadas. Mensagens de "pendente" mostram o que falta; elas não contam como resultado. Os exemplos pequenos de preparação apenas verificam o ambiente.

Rodar no computador

Use Python 3.11 ou 3.12. Abra um terminal dentro da pasta extraída:

```
python -m venv .venv
```

No Windows, ative com .venv\Scripts\activate; no Linux/macOS, com source .venv/bin/activate. Depois:

```
python -m pip install -r requirements.txt
python -m jupyterlab
```

Selecione o ambiente instalado como kernel. Não é necessário ter GPU. Se houver problema com processos auxiliares do carregamento, comece com num_workers=0 e justifique essa escolha.

Rodar no Google Colab

Abra um notebook novo, envie o ZIP pela aba de arquivos e execute:

```
from pathlib import Path
import zipfile

pacote = Path('/content/classroom-lab-02.zip')
with zipfile.ZipFile(pacote) as arquivo:
    arquivo.extractall('/content')
```

Em Arquivo -> Fazer upload de notebook, abra lab02.ipynb que está no pacote. No início desse notebook, use %cd /content/classroom-lab-02. O módulo apoio.py e a pasta dados/ devem estar no mesmo diretório de trabalho. O Colab normalmente já contém as bibliotecas principais; execute a célula de versões. Se faltar uma biblioteca, instale-a no próprio ambiente. Ao terminar, baixe o notebook executado: os arquivos do ambiente temporário não ficam automaticamente salvos no seu computador.

2. A base comum e a pergunta de classificação

A base sugerida é Red Wine Quality no Kaggle (https://www.kaggle.com/datasets/uciml/red-wine-quality-cortez-et-al-2009). O CSV deste pacote vem da fonte original UCI (https://archive.ics.uci.edu/dataset/186/wine+quality), com autoria e licença registradas em dados/FONTE-E-LICENCA.md. Assim, a atividade não depende de login no Kaggle para começar.

Uma linha representa uma observação de vinho tinto. Há 11 medidas numéricas e uma nota sensorial chamada quality. Para este exercício, defina:

```
y = (df['quality'] >= 7).astype('int64')
```

Classe 1: nota pelo menos 7. Classe 0: nota abaixo de 7. Esta fronteira é uma convenção do laboratório, não uma regra universal de qualidade. Imagine um sistema que seleciona amostras para uma análise especial: interessa encontrar a classe 1 usando apenas as medidas disponíveis antes da nota sensorial.

quality dá origem à resposta. Portanto, não pode entrar nas características do modelo correto. Também não entram alvo, identificadores de linha nem códigos criados para controlar a partição. Use exclusivamente as 11 colunas listadas no dicionário.

O arquivo é pequeno, tabular, real e desbalanceado depois da transformação do alvo. Não exige tratamento de texto ou imagens. Consulte as contagens verificadas no dicionário. Não confunda desbalanceamento moderado com o caso extremo de fraude discutido na aula.

Uma particularidade importante: perfis repetidos

Existem linhas com as mesmas 11 medidas. O pacote preserva o arquivo original. Para a avaliação principal, mantenha perfis idênticos no mesmo conjunto. Você pode agrupar pelas 11 características, sem usar o alvo, e fazer a separação por esses grupos. O notebook calcula grupo_perfil apenas para facilitar a identificação; esse código não é entrada do modelo.

Dois perfis iguais não provam que o vinho físico é o mesmo: a base não contém um identificador confiável dessa entidade. A regra é uma precaução didática para não avaliar repetidamente uma configuração que já apareceu no treino. Registre essa limitação. Também não há datas de coleta para fundamentar uma avaliação temporal real; não invente datas ou produtores para esta base.

3. O que entregar e em que ordem trabalhar

No repositório pessoal, organize:

```
lab-02/
  README.md             respostas, tabelas, gráficos e conclusão
  lab02.ipynb           notebook executado, saídas visíveis
  USO-DE-IA.md          declaração obrigatória
  apoio.py             apoio utilizado; registre se modificar
  requirements.txt     dependências
  dados/               CSV, dicionário e atribuição
  resultados/          imagens e tabelas que seu notebook exportar
```

Envie o link do repositório/pasta no Classroom, conforme o canal de entrega da turma. O ZIP disponibilizado pelo professor é o material de partida, não a sua entrega pronta. Não envie a pasta .venv nem caches de execução.

Parte	Valor	Evidência principal
A - Dataset e DataLoader	0,20	classe própria, justificativas, tempos e erro de BatchNorm
B - Partição	0,20	cinco análises e auditoria numérica da separação
C - Vazamento	0,30	dois experimentos com comparação e explicação
D - Métricas e decisão	0,30	modelo com parada antecipada, limiar escolhido na validação e relatório final

Fluxo recomendado: leitura -> B2 -> A -> reserva do teste -> C isolada no desenvolvimento -> D7 -> D4-D6 -> D1-D3 -> D8 -> revisão da entrega.

4. Parte A - Dataset e DataLoader · 0,20

A1. Implemente seu Dataset

Crie uma classe que herde de torch.utils.data.Dataset. Receba uma tabela de uma única partição, a lista de características e, opcionalmente, média e desvio já calculados. Escreva docstrings para explicar __init__, __len__ e __getitem__.

No treino, aprenda as estatísticas apenas com suas linhas. Na validação e no teste, receba e reutilize os mesmos valores do treino. Trate desvio zero para não produzir divisão por zero. Declare a convenção de desvio usada; pequenas diferenças entre implementações podem vir do denominador da variância.

Para um exemplo, devolva X com forma [11], tipo float32, e y escalar float32. Em um lote de tamanho B, as formas esperadas são [B, 11] e [B]. A rede de apoio devolve B logits; BCEWithLogitsLoss recebe logits diretamente, sem aplicar sigmoide antes da perda.

Mostre: comprimento do Dataset, formas e tipos de um exemplo e de um lote; ausência de NaN/infinito; e evidência de que validação e teste usaram as estatísticas do treino. Não exija média zero da validação: isso não é condição de correção.

A2. Configure três carregadores

Crie loader_treino, loader_validacao e loader_teste. Para cada um, justifique batch_size, shuffle, drop_last e num_workers. Diga qual é o efeito da escolha naquele conjunto; "é o padrão" não é justificativa.

Preserve todas as observações da avaliação. A ordem das previsões deve continuar alinhada à dos rótulos. Embaralhar o treino não troca a separação das partições. Múltiplos workers podem custar mais que ajudam numa base pequena; meça antes de alegar que aceleram.

Entregue: tabela com os três carregadores e seus quatro parâmetros, acompanhada das justificativas.

A3. Meça o tempo de uma época

Compare batch_size 1, 8, 64 e 512. Uma época completa percorre o conjunto de treino e executa previsão, perda, retropropagação e atualização. Medir só a criação do DataLoader não atende ao item.

Use a mesma rede, dados, dispositivo e configuração do otimizador. Comece cada medição do mesmo estado inicial e com um otimizador novo; não continue treinando o modelo da medição anterior. Use uma rede sem BatchNorm neste item, para que o lote 1 não interrompa a comparação. Não descarte observações para favorecer determinado tamanho de lote.

Faça um aquecimento fora da medição e, de preferência, três repetições por tamanho. Registre a mediana, o número de exemplos e de passos. Na GPU, sincronize antes e depois do intervalo; na CPU, time.perf_counter() basta. Salve o gráfico tempo × tamanho do lote, com unidades e descrição do equipamento.

Explique: onde o ganho diminuiu, o custo por passo e por que lotes diferentes também produzem quantidades diferentes de atualizações. Não invente um ponto de retorno decrescente se sua medição não o mostrou.

A4. Reproduza e corrija o erro de BatchNorm

Separe um subconjunto apenas do treino cujo tamanho deixe resto 1 na divisão pelo tamanho do lote. Por exemplo, 65 observações e lote 64 satisfazem a condição; confirme-a numericamente. Use uma rede com nn.BatchNorm1d e modo train().

Execute com drop_last=False, capture o erro esperado e imprima sua mensagem. Depois implemente uma correção apropriada e explique o custo da escolha: há observações descartadas, uma mudança de normalização ou outra alteração? A captura deve ser específica ao experimento; não esconda todos os erros do notebook com um except genérico.

Entregue: tamanho e resto, tamanho do lote que falhou, mensagem original, correção e justificativa. Esse subconjunto serve só à demonstração; não substitui a base principal. Mudar toda a rede para avaliação durante o treinamento não demonstra uma correção adequada do procedimento.

5. Parte B - A partição correta · 0,20

B1. Analise os cinco cenários

Para cada linha, escreva de três a cinco linhas: qual partição adotaria, qual uso futuro está pressupondo e que informação poderia atravessar os conjuntos numa divisão aleatória. Quando faltarem informações, declare a hipótese em vez de fabricar certeza. Em cenários sem dependência relevante, a divisão aleatória pode ser defensável; justifique.

Nº	Cenário
1	50.000 avaliações de produtos escritas por 3.000 usuários. Prever se a avaliação é positiva.
2	Leituras de vibração de 20 turbinas, de minuto em minuto, ao longo de dois anos. Prever falha nas próximas 24 horas.
3	200.000 e-mails rotulados como spam ou não, com 3% de spam.
4	8.000 radiografias de tórax de 900 pacientes. Prever presença de achado.
5	Transações de cartão de 2019 a 2026, de 500 mil clientes. Prever fraude.

No cenário 5, discuta explicitamente tempo e identidade do cliente. Diga como o objetivo de atender clientes conhecidos ou novos altera a avaliação. Não é necessário implementar esses cinco bancos nem escolher o mesmo tipo de partição para todos.

B2. Implemente e audite a base comum

Para Wine Quality, declare a pergunta de uso e implemente treino, validação e teste com proporções aproximadas de 60%, 20% e 20%. Use semente fixa e mantenha perfis idênticos juntos. Uma API possível é GroupShuffleSplit, aplicada primeiro para reservar o teste e depois para dividir o desenvolvimento. As proporções dessa API se referem a grupos; as quantidades de linhas podem variar.

Sua auditoria deve mostrar: quantidade de linhas por conjunto; identificadores de linha sem sobreposição; cobertura de todas as linhas; número de perfis compartilhados entre cada par de conjuntos igual a zero; presença de ambas as classes e proporções observadas. Não procure uma semente pela métrica final. Use a conferência de classes apenas como validação do desenho, antes de modelar.

Entregue: tabela de partições e verificações numéricas, acompanhadas de uma justificativa. Ausência de sobreposição de índices, sozinha, não prova ausência de repetição de características. Explique também o que a base não permite testar: futuro temporal, novos produtores e outros domínios não estão documentados.

6. Parte C - Vazamento reproduzido e quantificado · 0,30

Escolha duas formas diferentes da lista. Pelo menos uma deve usar dados reais; a base incluída atende a isso. Pelo menos uma deve ser das formas 2, 4 ou 7, como no enunciado original.

Forma	Mecanismo que deve ser demonstrado
1	Aprender o pré-processamento com dados que deveriam estar reservados.
2	Incluir o alvo ou uma informação derivada dele entre as características.
3	Usar informação que só existirá depois do momento da previsão.
4	Permitir duplicatas entre os conjuntos de aprendizagem e avaliação.
5	Misturar a mesma entidade em conjuntos que deveriam representar entidades novas.
6	Selecionar características usando também as respostas da avaliação.
7	Usar repetidamente o teste para escolher modelo, configuração ou limiar.

Um caminho simples é investigar 1 e 2 na base comum. Outra possibilidade é estudar perfis repetidos na forma 4. A escolha e a implementação são suas. Para os mecanismos temporal e por entidade real, esta base não traz os metadados necessários: use outra fonte documentada ou dados sintéticos identificados como tais, respeitando a exigência de ao menos um experimento real.

Separe o experimento de erro da avaliação principal

Use somente as linhas de treino + validação da B2 para criar partições internas da Parte C. O teste principal da D deve continuar reservado. Nomeie as variáveis com o prefixo c_ para não substituir, sem perceber, os dados, estatísticas ou modelo da D.

Para cada forma:

1. Descreva qual informação deveria estar protegida e em qual etapa ela atravessa a fronteira.
2. Defina o conjunto de desenvolvimento interno, a avaliação interna, o modelo e a métrica antes de comparar.
3. Execute o procedimento incorreto, identificando-o no código.
4. Execute a versão corrigida. Mantenha comparáveis dados, semente e configuração sempre que possível. Se a correção exige mudar a partição, explique a consequência para a comparação.
5. Registre os dois valores e a diferença. Para acurácia entre 0 e 1, a diferença em pontos percentuais é 100 * (errado - correto).
6. Explique por que os resultados sustentam, ou limitam, sua interpretação. Uma pequena diferença ou uma diferença de sinal inesperado não invalida automaticamente a existência do vazamento.

Forma	Dados usados	Métrica	Incorreto	Corrigido	Diferença/unidade	Informação indevida
preencher	preencher	preencher	medir	medir	calcular	explicar

Se escolher a forma 7, reserve quatro conjuntos internos desde o início. Faça a seleção indevida entre os 50 candidatos pelo teste interno e avalie o escolhido no quarto conjunto, intocado até então. Compare com uma seleção orientada pela validação interna, usando o mesmo orçamento de candidatos. Nenhum desses conjuntos substitui o teste principal da D. Não use o quarto conjunto para corrigir a busca depois de ver o resultado.

Entregue: dois experimentos executados, tabela e um parágrafo explicativo por forma. Não replique observações ou tente sementes sucessivas apenas para produzir um efeito maior. Se introduzir uma coluna indevida artificialmente para demonstrar o mecanismo, declare exatamente essa transformação.

7. Parte D - Métricas e recomendação de limiar · 0,30

Use as partições principais da B2 e a classe positiva quality >= 7. O classificador principal deve ser uma rede binária pequena em PyTorch, com parada antecipada. O arquivo apoio.py oferece uma arquitetura de referência, funções de treino por época, perda e escores. Uma regressão logística adicional é opcional e não substitui a D7.

Comece com uma rede 11 -> 16 -> 1, ReLU, Adam e BCEWithLogitsLoss sem ponderação. Esses valores são uma referência de baixo custo, não uma promessa de desempenho. Registre qualquer mudança e faça escolhas somente na validação. Converter logit em escore com sigmoide não garante calibração.

D7 primeiro: aprenda e restaure o melhor estado

Implemente parada antecipada monitorando a perda de validação. Defina antes o máximo de épocas, a paciência e a melhora mínima; sugestões: 100 épocas, paciência 10 e melhora mínima de 0,0001. A cada época, treine, avalie sem gradientes e decida se houve melhora.

Ao melhorar, guarde uma cópia independente dos pesos, a época e a perda. Uma referência mutável ao state_dict pode continuar mudando durante o treino. Ao esgotar a paciência, pare e restaure os pesos guardados antes de gerar escores para decidir o limiar.

Mostre: curvas de perda de treino e validação, época de parada, melhor época, melhor perda e confirmação da restauração. Se o máximo de épocas chegar primeiro, informe isso; não diga que a paciência disparou quando não disparou. Não monitore a perda do teste durante esse laço.

D4. Declare a decisão e os custos

No contexto didático de selecionar amostras de alta nota, defina o que ocorre quando o sistema prevê positivo e quando prevê negativo. Então descreva:

- Falso positivo: selecionar como alta nota uma observação com nota abaixo de 7.
- Falso negativo: deixar de selecionar uma observação com nota pelo menos 7.

Proponha C_FP > 0 e C_FN > 0, numa unidade consistente. Podem ser unidades de esforço, pontos de custo ou valores hipotéticos. Esta base não fornece preços, perdas ou custos operacionais reais. Escreva explicitamente que são hipóteses do exercício e justifique a relação entre eles. Para simplificar, considere custo zero para acertos. A qualidade da justificativa vale mais que a magnitude escolhida.

D5. Escolha o limiar na validação

Com o melhor modelo restaurado, obtenha escores na validação. Para cada limiar candidato, classifique positivo quando escore >= limiar e calcule:

```
custo = C_FP × número de falsos positivos + C_FN × número de falsos negativos
```

Avalie os escores únicos e os extremos que representam todas as previsões positivas ou negativas; se usar uma grade, declare a resolução e que ela é uma aproximação. Declare também como desempatar limiares de custo igual. Compare o escolhido com 0,5 na mesma validação e informe custo total e custo médio por observação.

Fixe a regra de desempate, o modelo, as características, as estatísticas e o limiar antes da avaliação final. A mesma validação orienta a parada e o limiar neste laboratório; reconheça esse uso de desenvolvimento. Seus números de validação não são a estimativa independente final.

D6. Compare a busca com a fórmula

Calcule C_FP / (C_FP + C_FN) e compare com o corte encontrado. A fórmula assume probabilidades apropriadas à população, custos de erro constantes e custo zero para acertos. Sua validade não decorre apenas do nome predict_proba ou da sigmoide.

Investigue diferenças: amostra pequena, escores mal calibrados, grade de busca, pesos de classe ou reamostragem. Um diagrama de calibração na validação e o Brier score podem apoiar a discussão, sem provar calibração perfeita. Não ajuste o modelo depois de olhar o teste para fazer as duas respostas coincidirem.

D1 e D2. Abra a avaliação final e produza a tabela

Use o teste principal depois de fixar as escolhas. Gere os escores uma vez e calcule, com a regra escolhida: matriz de confusão, acurácia, precisão, revocação, F1 e AUC-ROC. Para a curva precisão-revocação, informe a área trapezoidal AUC-PR. Se também usar average_precision_score, rotule-a AP: ela não é, em geral, a mesma área.

Apresente a proporção positiva do conjunto avaliado. A matriz deve ter rótulos e orientação explícitos: linhas reais e colunas previstas, na ordem 0 e 1. Calcule AUCs com escores, não com as classes após o corte. Declare a convenção usada se nenhuma previsão positiva for produzida.

Construa o classificador trivial usando a classe majoritária identificada no treino e avalie-o no mesmo teste. Compare a acurácia e a capacidade de encontrar positivos. Faça a tabela de 0,5 e do limiar previamente fixado; a comparação no teste serve para relatar essas duas regras já definidas, não para escolher uma terceira.

Regra	Limiar	Acurácia	Precisão	Revocação	F1	AUC-ROC	AUC-PR	Custo/observação
Trivial do treino	não se aplica	medir	medir	medir	medir	justificar	justificar	medir
Rede: padrão	0,5	medir	medir	medir	medir	medir	medir	medir
Rede: escolhido na validação	fixado	medir	medir	medir	medir	medir	medir	medir

As AUCs da rede são iguais nas duas linhas quando os escores são os mesmos: o limiar muda as classes, não o ordenamento. Para um baseline constante, declare qual escore constante usou ou marque as áreas como não reportadas; não crie uma curva inexistente a partir de uma única matriz.

D3. Desenhe as duas curvas

Plote ROC e precisão-revocação lado a lado, com nomes dos eixos e áreas calculadas. Na ROC, a referência aleatória é a diagonal de (0,0) a (1,1), cuja área é 0,5; não uma linha horizontal em 0,5. Na PR, use a linha horizontal correspondente à prevalência positiva do teste.

D8. Escreva para quem decide

Conclua com um parágrafo: qual ação o modelo apoia, qual limiar foi fixado, quais métricas e custos foram observados no teste, qual erro merece atenção e quais limitações continuam abertas. Identifique custos como hipotéticos. Não transforme desempenho neste arquivo em garantia para

produtores, regiões ou períodos que não foram avaliados.

Entregue na D: histórico de treino, restauração, matriz de custos, busca na validação, comparação com a fórmula, duas matrizes de confusão da rede, tabela final, curvas e recomendação. Mantenha separadas a evidência usada para escolher e a evidência usada para avaliar.

8. Como a nota é composta

Os valores máximos de A, B, C e D são 0,20, 0,20, 0,30 e 0,30. Dentro de cada parte, a correção considera estas dimensões; elas não constituem pontos adicionais:

Dimensão	Peso	Evidência
Execução	25%	Código roda do zero e mantém saídas visíveis.
Correção técnica	30%	Partições e métricas corretas, mecanismos de vazamento demonstrados.
Análise	30%	Explicação das causas, limitações e escolhas.
Comunicação	15%	Texto legível, tabelas e gráficos identificados.

As regras de penalização do laboratório continuam aplicáveis:

Situação	Efeito previsto
Notebook não executa	Execução = 0 e -50% nas demais dimensões.
Vazamento na própria Parte D não detectado	-40%.
Vazamento detectado e documentado pelo estudante	Sem penalidade por essa descoberta; registrar a correção.
Métrica de treino reportada como resultado de avaliação	-30%.
Experimento inflado para parecer dramático	-20% na dimensão Análise.
Ausência de USO-DE-IA.md	Nota zero.
Atraso de até 48 horas	-20%.

Bônus de até 0,1: demonstrar uma oitava forma de vazamento, com medição e explicação, ou documentar um mecanismo de vazamento em uma base pública conhecida. Repetir o alerta de duplicatas já fornecido neste pacote, sem investigação adicional, não constitui uma descoberta nova.

9. Checklist antes de enviar

- B2: todas as linhas cobertas, nenhuma linha ou perfil compartilhado, ambas as classes nos conjuntos.
- A: estatísticas aprendidas no treino; tipos e formas corretos; quatro tempos medidos; erro de BatchNorm documentado.
- C: duas formas, ao menos uma real e uma entre 2/4/7; comparação e diferença com unidade; teste principal preservado.

- D: melhor estado restaurado; limiar escolhido na validação; teste usado depois das escolhas; matriz, curvas e custos identificados.

- Relatório: nenhum valor inventado; resultados pequenos ou desfavoráveis também explicados.

- Entrega: notebook reiniciado e executado, README preenchido, declaração de IA, fonte dos dados e versões.

- Arquivos de resposta: nenhum marcador TODO tratado como conclusão ou célula "pendente" como evidência.

10. Dúvidas frequentes e apoio

Preciso baixar a base do Kaggle? Não. O mesmo conjunto tem uma fonte original pública; o CSV já está incluído, com atribuição. A indicação do Kaggle serve para conhecer sua página e outros trabalhos, não para copiar resultados.

Posso usar o banco do meu projeto? A atividade está preparada para a base comum, sem exigir um domínio particular. Uma substituição deve atender a todos os requisitos e ser combinada com o professor; não é necessária para concluir este material.

Por que a acurácia trivial é alta? Calcule as proporções. A predominância de uma classe pode tornar esse indicador pouco informativo sozinho. Explique com seus resultados, não com a frase pronta "acurácia não presta".

O vazamento mudou pouco a métrica. Fiz errado? Não necessariamente. Investigue o mecanismo e reporte a medição. Não é exigido obter a diferença mostrada nos slides.

Pipeline resolve tudo? Ele organiza transformações e pode evitar ajustes no conjunto errado quando usado corretamente. Não corrige sozinho grupos misturados, uma coluna com informação do futuro ou escolhas feitas olhando o teste.

Posso usar IA? Registre ferramenta, finalidade, trecho aproveitado e como verificou. Se não usou, declare isso no arquivo obrigatório. Você deve conseguir explicar cada linha entregue.

A base não apareceu no Colab. Confira o diretório atual, a extração da pasta classroom-lab-02/ e a existência de dados/winequality-red.csv. A leitura usa separador ;, não vírgula.

O DataLoader travou. Teste num_workers=0, confira se o kernel usa o ambiente correto e registre a condição. Evite executar criação de processos em paralelo no Windows sem proteger o ponto de entrada de scripts.

Fontes de apoio: Dataset/DataLoader no PyTorch (https://docs.pytorch.org/docs/stable/data.html), BCEWithLogitsLoss (https://docs.pytorch.org/docs/stable/generated/torch.nn.BCEWithLogitsLoss.html), GroupShuffleSplit (https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupShuffleSplit.html), métricas (https://scikit-learn.org/stable/modules/model_evaluation.html), escolha de limiar (https://scikit-learn.org/stable/modules/classification_threshold.html) e cuidados com vazamento (https://scikit-learn.org/stable/common_pitfalls.html).